

Clase 6

De describir datos a cuantificar incertidumbre

Diplomado de Python y Análisis de Datos

Universidad Marista

2026

Objetivo de la sesión

Al finalizar la clase, el estudiante será capaz de:

- distinguir entre población y muestra;
- diferenciar parámetros y estadísticos;
- interpretar medidas de tendencia central y dispersión;
- analizar distribuciones;
- comprender el Teorema Central del Límite;
- interpretar el error estándar;
- construir intervalos de confianza;
- formular hipótesis estadísticas;
- interpretar correctamente un valor p ;
- comparar dos grupos mediante una prueba t ;
- distinguir significancia estadística de relevancia práctica.

Tiempo	Tema
0:00–0:10	Problema inicial: ¿una diferencia observada es real?
0:10–0:25	Población, muestra, parámetros y estadísticos
0:25–0:45	Media, mediana, varianza, desviación y percentiles
0:45–1:00	Distribuciones y distribución normal
1:00–1:20	Muestreo y Teorema Central del Límite
1:20–1:30	Error estándar e introducción a inferencia
1:30–1:40	Descanso
1:40–1:55	Intervalos de confianza
1:55–2:15	Hipótesis nula, alternativa y valor p
2:15–2:30	Prueba t y comparación de medias
2:30–2:40	Correlación y significancia práctica
2:40–2:55	Statistical Detective Challenge
2:55–3:00	Conclusiones y conexión con Series Temporales

El problema inicial

Supongamos que una empresa prueba dos versiones de una página web.

	Versión A	Versión B
Conversión	12.1 %	13.0 %

Pregunta

¿Podemos afirmar inmediatamente que la versión B es mejor?

No necesariamente.


¿Qué nos falta saber?

Una diferencia observada puede depender de:

- tamaño de muestra;
- variabilidad de los datos;
- forma de la distribución;
- diseño del experimento;
- sesgo de selección;
- incertidumbre muestral;
- magnitud real del efecto.

Idea central

La estadística nos ayuda a distinguir entre señal y ruido.



Pregunta

¿El patrón que observamos es suficientemente sólido para tomar una decisión?

Estadística descriptiva

La estadística descriptiva resume los datos observados.

Herramientas:

- media;
- mediana;
- moda;
- varianza;
- desviación estándar;
- percentiles;
- tablas;
- visualizaciones.

Ejemplo

¿Cuál fue el gasto promedio de los clientes observados?

Estadística inferencial

La estadística inferencial busca utilizar una muestra para obtener conclusiones sobre una población.

Herramientas:

- estimación;
- distribuciones muestrales;
- error estándar;
- intervalos de confianza;
- pruebas de hipótesis;
- significancia estadística.

Ejemplo

¿Podemos inferir el gasto promedio de todos los clientes utilizando una muestra?

Descriptiva vs inferencial

Descriptiva

Pregunta:

¿Qué ocurrió en los datos observados?

Inferencial

Pregunta:

¿Qué podemos concluir más allá de los datos observados?

¿Qué es una población?


Una **población** es el conjunto completo de elementos que queremos estudiar.

Ejemplos:

- todos los clientes de una empresa;
- todos los estudiantes de una universidad;
- todas las transacciones de un año;
- todas las piezas producidas por una fábrica;
- todos los usuarios de una aplicación.

¿Qué es una muestra?

Una **muestra** es un subconjunto de la población.



¿Por qué trabajar con muestras?

Porque estudiar toda la población puede ser:

- muy costoso;
- muy lento;
- computacionalmente complejo;
- imposible;
- innecesario cuando una muestra adecuada puede proporcionar una buena estimación.

Parámetro vs estadístico

Parámetro

Describe a la población.

Ejemplo:

μ

Media poblacional.

Estadístico

Se calcula con una muestra.

Ejemplo:

$\bar{x}$

Media muestral.

Muestra



Estadístico



Estimación del parámetro

Una muestra puede estar sesgada

Supongamos:

Queremos medir la satisfacción de todos los estudiantes, pero solamente encuestamos a quienes asistieron hoy.

Pregunta

¿La muestra representa necesariamente a toda la población?

No.

Ejemplo de sesgo

Queremos conocer el uso de redes sociales de una población.
Pero publicamos la encuesta solamente en Instagram.

La muestra podría sobre-representar:

- usuarios activos de Instagram;
- personas con determinadas edades;
- ciertos hábitos digitales.

Idea

El proceso de selección de la muestra importa.

Más datos no corrigen todo

Podemos tener:

1 000 000

observaciones.

Pero si la muestra está sistemáticamente sesgada:

más datos $\neq$ mejor inferencia

Lección

Una muestra enorme puede seguir representando mal a la población.

Media

La media aritmética es:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

En Pandas:

```
1 media = df["ingreso"].mean()  
2  
3 print(media)
```

Interpretación

Representa el centro aritmético de las observaciones.

Mediana

La mediana es el valor central después de ordenar las observaciones.

```
1 mediana = df["ingreso"].median()  
2  
3 print(mediana)
```

Ejemplo:

10, 11, 12, 13, 1000

Media vs mediana

Para:

10, 11, 12, 13, 1000

tenemos:

Media

209.2

Mediana

12

Pregunta

¿Cuál representa mejor el valor típico de este grupo?

Moda

La moda representa el valor más frecuente.

```
1 moda = df["categoria"].mode()  
2  
3 print(moda)
```

Es muy útil para variables categóricas.

Ejemplos:

- categoría más frecuente;
- ciudad más común;
- producto más observado;
- tipo de membresía dominante.

El promedio no cuenta toda la historia

Consideremos:

Grupo A

48, 49, 50, 51, 52

Grupo B

10, 30, 50, 70, 90

Ambos tienen media:

50

pero presentan comportamientos muy diferentes.

Rango

El rango mide la distancia entre el máximo y el mínimo:

$$R = x_{\text{máx}} - x_{\text{mín}}$$

En Pandas:

```
1 rango = (  
2     df["ventas"].max()  
3     - df["ventas"].min()  
4 )  
5  
6 print(rango)
```

Limitación

El rango depende solamente del mínimo y máximo.

Varianza

La varianza muestral puede expresarse como:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

En Pandas:

```
1 varianza = df["ventas"].var()  
2  
3 print(varianza)
```

Interpretación

Mide cuánto se alejan, en promedio cuadrático, los datos respecto de la media.

Desviación estándar

La desviación estándar es:

$$s = \sqrt{s^2}$$

En Pandas:

```
1 desviacion = df["ventas"].std()  
2  
3 print(desviacion)
```

Idea

Una desviación estándar mayor indica mayor dispersión.

Misma media, diferente dispersión

	Grupo A	Grupo B
Media	50	50
Dispersión	Baja	Alta

Lección

Una media debería interpretarse junto con una medida de dispersión.

Coeficiente de variación

Una medida relativa de dispersión es:

$$CV = \frac{s}{\bar{x}}$$

Ejemplo:

	Producto A	Producto B
Media	100	1000
Desv. estándar	10	50

El coeficiente permite comparar variabilidad relativa.

Percentiles

Los percentiles indican la posición relativa de un valor.

En Pandas:

```
1 q1 = df["ventas"].quantile(0.25)
2
3 mediana = df["ventas"].quantile(0.50)
4
5 q3 = df["ventas"].quantile(0.75)
6
7 p95 = df["ventas"].quantile(0.95)
8
9 print(q1, mediana, q3, p95)
```

Interpretación de percentiles

Supongamos que un cliente está en el:

$$P_{95}$$

de gasto.

Podemos interpretar que su gasto es superior aproximadamente al 95 % de las observaciones del dataset.

Aplicaciones:

- segmentación de clientes;
- detección de valores extremos;
- análisis de rendimiento;
- riesgo;
- calidad.

¿Qué es una distribución?

Una distribución describe:

- dónde se concentran los datos;
- qué tan dispersos están;
- qué forma tienen;
- si existe asimetría;
- si existen colas;
- si aparecen valores extremos;
- si existen varios grupos.

Visualizar una distribución

```
1 import seaborn as sns
2 import matplotlib.pyplot as plt
3
4 sns.histplot(
5     data=df,
6     x="ventas",
7     kde=True
8 )
9
10 plt.title(
11     "Distribucion de ventas"
12 )
13
14 plt.show()
```

¿Qué buscamos en una distribución?

- simetría;
- sesgo positivo;
- sesgo negativo;
- concentración;
- dispersión;
- multimodalidad;
- valores extremos.

Pregunta

¿Qué información observamos aquí que una media no puede mostrarnos?

Distribución normal

La distribución normal es uno de los modelos probabilísticos más importantes.

Características:

- simétrica;
- forma de campana;
- máxima concentración cerca del centro;
- menor frecuencia hacia las colas;
- media, mediana y moda coinciden en el modelo ideal.

Importante

No todos los datos reales siguen una distribución normal.

Para una variable aproximadamente normal:

$$\mu \pm 1\sigma \approx 68 \%$$

$$\mu \pm 2\sigma \approx 95 \%$$

$$\mu \pm 3\sigma \approx 99.7 \%$$

Ejemplo de la regla empírica

Supongamos:

$$\mu = 100$$

$$\sigma = 10$$

Entonces aproximadamente:

$$68 \% \rightarrow [90, 110]$$

$$95 \% \rightarrow [80, 120]$$

$$99.7 \% \rightarrow [70, 130]$$

Z-score

El z-score indica cuántas desviaciones estándar separan un valor de la media:

$$z = \frac{x - \mu}{\sigma}$$

Ejemplo:

$$\mu = 100$$

$$\sigma = 10$$

$$x = 130$$

Entonces:

$$z = 3$$

Z-score en Python

```
1 from scipy.stats import zscore
2
3 df["z_ventas"] = zscore(
4     df["ventas"]
5 )
6
7 print(
8     df[
9         ["ventas", "z_ventas"]
10    ].head()
11 )
```

Aplicaciones:

- estandarización;
- detección exploratoria de extremos;
- comparación entre escalas.

Ejemplo de sesgo positivo

Consideremos ingresos:

15000, 20000, 23000, 27000, 30000, 300000

La mayoría está relativamente concentrada.

Pero existe un valor muy grande.

Esto genera una cola hacia la derecha.

Frecuentemente:

$$\text{media} > \text{mediana}$$

¿Media o mediana?

Media

Útil cuando queremos representar el centro aritmético y los extremos no dominan excesivamente.

Mediana

Especialmente útil cuando existen valores extremos o distribuciones fuertemente sesgadas.

Lección

No existe una medida universalmente mejor. Depende del problema y de la distribución.

Variabilidad muestral

Supongamos que tomamos diferentes muestras de la misma población.

Muestra	Media
A	850
B	872
C	844

Pregunta

¿Por qué cambia la media?

Porque cada muestra contiene observaciones diferentes.

Tomar una muestra con Pandas

```
1 muestra = df.sample(  
2     n=100,  
3     random_state=42  
4 )  
5  
6 media = muestra["ventas"].mean()  
7  
8 print(media)
```

Si cambiamos la muestra, la media puede cambiar.

Cambiar la muestra

```
1 muestra_1 = df.sample(  
2     n=100,  
3     random_state=42  
4 )  
5  
6 muestra_2 = df.sample(  
7     n=100,  
8     random_state=7  
9 )  
10  
11 print(  
12     muestra_1["ventas"].mean()  
13 )  
14  
15 print(  
16     muestra_2["ventas"].mean()  
17 )
```

Tamaño de muestra

En general, cuando aumenta el tamaño de una muestra aleatoria adecuada:

- las estimaciones tienden a ser más estables;
- disminuye parte de la incertidumbre muestral;
- mejora la precisión estadística.

Pero...

Aumentar n no corrige automáticamente sesgos sistemáticos.

Comparar tamaños de muestra

```
1 m10 = (  
2     df.sample(10) ["ventas"]  
3     .mean()  
4 )  
5  
6 m100 = (  
7     df.sample(100) ["ventas"]  
8     .mean()  
9 )  
10  
11 m1000 = (  
12     df.sample(1000) ["ventas"]  
13     .mean()  
14 )  
15  
16 print(m10)  
17 print(m100)  
18 print(m1000)
```

Ley de los Grandes Números

De manera conceptual:

A medida que aumenta el tamaño de una muestra aleatoria adecuada, la media muestral tiende a acercarse a la media poblacional.

Ejemplo conceptual:

Tamaño	Media
10	930
100	861
1000	852
10000	849

Teorema Central del Límite

Supongamos que tomamos muchas muestras aleatorias de una población.
Para cada muestra calculamos:

$$\bar{x}$$

Si repetimos el procedimiento muchas veces, obtenemos una **distribución de medias muestrales**.

Teorema Central del Límite

Bajo condiciones apropiadas, cuando el tamaño de muestra aumenta, la distribución de la media muestral tiende aproximadamente a una distribución normal.

Una idea sorprendente

La población original:

no necesita ser normal

Sin embargo, bajo condiciones apropiadas y con muestras suficientemente grandes:


$$\bar{X}$$

puede presentar una distribución aproximadamente normal.

Importancia

Esta propiedad es fundamental para muchos procedimientos de inferencia.

De población a distribución muestral



Simulando el Teorema Central del Límite

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 poblacion = np.random.exponential(
5     scale=10,
6     size=100000
7 )
8
9 medias = []
10
11 for _ in range(5000):
12
13     muestra = np.random.choice(
14         poblacion,
15         size=50
16     )
17
18     medias.append(
19         muestra.mean()
20     )
21
22 plt.hist(
```


Error estándar

La desviación estándar describe la dispersión de las observaciones.

El **error estándar** describe la variabilidad esperada de una estimación.

Para la media:

$$SE = \frac{s}{\sqrt{n}}$$

donde:

- s = desviación estándar muestral;
- n = tamaño de muestra.

¿Qué ocurre cuando aumenta n ?

Tenemos:

$$SE = \frac{s}{\sqrt{n}}$$

Si aumenta:

n

entonces:

$SE \downarrow$

Interpretación

En general, una muestra mayor permite estimar la media con mayor precisión, si el diseño de muestreo es adecuado.

DESCANSO

10 minutos

Al regresar:

¿Cómo cuantificamos la incertidumbre de una estimación?

Una estimación puntual

Supongamos que nuestra muestra produce:

$$\bar{x} = 850$$

Podemos decir:

“La media estimada es 850”

Pero otra muestra podría producir:

842

o:

861

Por eso necesitamos expresar incertidumbre.

Intervalo de confianza

Un intervalo de confianza proporciona un rango de valores plausibles para un parámetro bajo un procedimiento estadístico determinado.

De forma aproximada, para ciertos casos:

$$\bar{x} \pm 1.96(SE)$$

para un nivel del 95 %.

Ejemplo

Supongamos:

$$\bar{x} = 850$$

y:

$$SE = 20$$

Entonces:

$$850 \pm 1.96(20)$$

$$850 \pm 39.2$$

Por lo tanto:

$$[810.8, 889.2]$$

Interpretación frecuentista

Una interpretación adecuada es:

Si repitiéramos el procedimiento muchas veces, aproximadamente el 95 % de los intervalos contruidos de esta forma contendrían el parámetro verdadero, bajo los supuestos del método.

Idea práctica

El intervalo comunica precisión e incertidumbre.

Intervalo de confianza con SciPy

```
1 import scipy.stats as stats
2
3 datos = df["ventas"].dropna()
4
5 media = datos.mean()
6
7 sem = stats.sem(datos)
8
9 ic = stats.t.interval(
10     confidence=0.95,
11     df=len(datos)-1,
12     loc=media,
13     scale=sem
14 )
15
16 print("Media:", media)
17
18 print("IC 95%:", ic)
```


Intervalo ancho vs estrecho

Un intervalo más estrecho suele indicar:

mayor precisión

Puede depender de:

- tamaño de muestra;
- variabilidad;
- nivel de confianza;
- modelo estadístico.

Precisión no significa ausencia de sesgo

Podemos tener:

un intervalo muy estrecho

pero construido sobre una muestra sesgada.

Entonces tendremos una estimación:

precisa pero equivocada

Lección

Precisión y exactitud no son exactamente lo mismo.

Una nueva pregunta

Una empresa modifica su estrategia comercial.

Antes:

$$\bar{x}_A = 820$$

Después:

$$\bar{x}_B = 860$$

Pregunta

¿La diferencia refleja un cambio real o podría aparecer por variabilidad muestral?

Hipótesis nula

La hipótesis nula se representa como:

$$H_0$$

Usualmente representa:

ausencia de efecto o diferencia

Por ejemplo:

$$H_0 : \mu_A = \mu_B$$

Hipótesis alternativa

La hipótesis alternativa se representa:

$$H_1$$


Ejemplo bilateral:

$$H_1 : \mu_A \neq \mu_B$$

Ejemplo direccional:

$$H_1 : \mu_B > \mu_A$$

La lógica de una prueba estadística



¿Qué es el valor p ?

El valor p es:

La probabilidad, suponiendo que la hipótesis nula y el modelo del test son correctos, de obtener un resultado al menos tan extremo como el observado.

Muy importante

El valor p NO es la probabilidad de que H_0 sea verdadera.

Nivel de significancia

Un valor utilizado frecuentemente es:

$$\alpha = 0.05$$

Si:

$$p < \alpha$$

rechazamos H_0 bajo ese criterio.

Si:

$$p \geq \alpha$$

no encontramos evidencia suficiente para rechazar H_0 .

No rechazar no significa demostrar

Si obtenemos:

$$p = 0.30$$

no debemos decir:

“Demostramos que ambos grupos son iguales.”

La interpretación correcta es:

“No encontramos evidencia suficiente para rechazar la hipótesis nula.”

Error tipo I

Ocorre cuando:

rechazamos H_0

cuando en realidad:

H_0 era cierta.

Puede interpretarse como:

falsa alarma

Error tipo II

Ocurre cuando:

no rechazamos H_0

cuando realmente:

existe un efecto.

Puede interpretarse como:

no detectar una señal real

Tipo I

Concluimos que una campaña funciona.
Pero realmente no produce mejora.

Tipo II

Concluimos que no existe mejora.
Pero realmente la campaña sí funciona.

Significancia estadística

Supongamos:

Grupo	Promedio
A	\$100.00
B	\$100.03

Con millones de observaciones podríamos encontrar:

$$p < 0.001$$

Pregunta

¿Una diferencia de tres centavos importa?

No necesariamente.

Dos preguntas diferentes

Valor p

Pregunta:

¿Existe evidencia de una diferencia?

Tamaño del efecto

Pregunta:

¿Qué tan grande es la diferencia?

Lección

Significancia estadística no implica automáticamente relevancia práctica.

Caso práctico: Experimento A/B

Tenemos dos grupos:

- Grupo A: experiencia actual;
- Grupo B: nueva experiencia.

Queremos determinar:

¿El gasto promedio cambió?

Dataset:

`experimento_marketing.csv`

Paso 1: cargar el dataset

```
1 import pandas as pd
2
3 df = pd.read_csv(
4     "experimento_marketing.csv"
5 )
6
7 print(df.head())
8
9 print(df.shape)
10
11 df.info()
```


Paso 2: descriptiva por grupo

```
1 resumen = (  
2     df.groupby("grupo")["gasto"]  
3     .agg([  
4         "count",  
5         "mean",  
6         "median",  
7         "std"  
8     ])  
9 )  
10  
11 print(resumen)
```

Regla

Antes de aplicar una prueba estadística debemos conocer los datos.

Paso 3: visualizar

```
1 import seaborn as sns
2 import matplotlib.pyplot as plt
3
4 sns.boxplot(
5     data=df,
6     x="grupo",
7     y="gasto"
8 )
9
10 plt.title(
11     "Distribucion del gasto por grupo"
12 )
13
14 plt.show()
```

Pregunta antes de probar

Después de observar la gráfica:

¿Parece existir una diferencia?

Pero recuerda:

Regla

Una diferencia visual no demuestra por sí sola una diferencia estadística.

Paso 4: separar grupos

```
1 grupo_a = df.loc[
2     df["grupo"] == "A",
3     "gasto"
4 ].dropna()
5
6 grupo_b = df.loc[
7     df["grupo"] == "B",
8     "gasto"
9 ].dropna()
10
11 print(
12     grupo_a.mean()
13 )
14
15 print(
16     grupo_b.mean()
17 )
```

Formular hipótesis

Hipótesis nula:

$$H_0 : \mu_A = \mu_B$$

Hipótesis alternativa:

$$H_1 : \mu_A \neq \mu_B$$

Pregunta

¿Existe evidencia de que el gasto promedio de ambos grupos sea diferente?

Paso 5: Welch t-test

```
1 from scipy.stats import ttest_ind
2
3 t_stat, p_value = ttest_ind(
4     grupo_a,
5     grupo_b,
6     equal_var=False
7 )
8
9 print(
10     "t-statistic:",
11     t_stat
12 )
13
14 print(
15     "p-value:",
16     p_value
17 )
```

¿Por qué Welch?

La prueba t de Welch permite comparar las medias de dos grupos independientes. Una ventaja es que:

no exige asumir exactamente la misma varianza en ambos grupos.

Importante

Toda prueba estadística tiene supuestos que debemos considerar.

Paso 6: decisión estadística

```
1 alpha = 0.05
2
3 if p_value < alpha:
4
5     print(
6         "Hay evidencia de una diferencia."
7     )
8
9 else:
10
11     print(
12         "No hay evidencia suficiente."
13     )
```


Pero todavía falta algo

Supongamos:

$$p = 0.01$$

Entonces encontramos evidencia estadística.

Pero todavía debemos preguntar:

¿Cuánto cambió?

Ese es el puente hacia la magnitud del efecto.

Paso 7: diferencia observada

```
1 media_a = grupo_a.mean()
2
3 media_b = grupo_b.mean()
4
5 diferencia = (
6     media_b
7     - media_a
8 )
9
10 print(
11     "Media A:",
12     media_a
13 )
14
15 print(
16     "Media B:",
17     media_b
18 )
19
20 print(
21     "Diferencia:",
22     diferencia
```

Tamaño del efecto

Una medida clásica es Cohen's d :

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{\text{pooled}}}$$

Conceptualmente:

Valor p



¿Existe evidencia?

Effect Size



¿Qué tan grande es el efecto?

Podemos estudiar asociaciones entre variables numéricas:

```
1 correlacion = df[
2     [
3         "publicidad",
4         "ventas"
5     ]
6 ].corr()
7
8 print(correlacion)
```

Podríamos obtener:

$$r = 0.82$$

Interpretación de correlación

Un valor cercano a:

+1

indica una asociación lineal positiva fuerte.

Un valor cercano a:

-1

indica una asociación lineal negativa fuerte.

Un valor cercano a:

0

indica poca asociación lineal.

Correlación no implica causalidad

Encontrar:

$$X \leftrightarrow Y$$

no demuestra:

$$X \rightarrow Y$$

Podrían existir:

- variables confusoras;
- causalidad inversa;
- selección;
- coincidencias;
- relaciones indirectas.

Ejemplo clásico

Podemos observar:

Ventas de helado



Casos de insolación



¿El helado causa insolación?

No necesariamente.

Una tercera variable podría explicar ambas:

Temperatura

Statistical Detective

Marketing afirma:

“La campaña B es mejor que la campaña A.”

Su misión:

determinar si los datos respaldan esa afirmación.

Dataset del reto

Archivo:

`campania_ab.csv`

Variables:

- `id_usuario;`
- `grupo;`
- `edad;`
- `region;`
- `conversion;`
- `gasto;`
- `tiempo_sitio.`

Paso 1: explorar

Cada equipo debe determinar:

- tamaño de los grupos;
- media;
- mediana;
- desviación estándar;
- valores faltantes;
- posibles outliers.

Código de apoyo

```
1 resumen = (  
2     df.groupby("grupo")["gasto"]  
3     .agg([  
4         "count",  
5         "mean",  
6         "median",  
7         "std"  
8     ])  
9 )  
10  
11 print(resumen)
```

Paso 2: visualizar

Cada equipo debe crear al menos una gráfica.

Opciones:

- boxplot;
- histograma;
- gráfica de comparación de medias.

Regla

La visualización debe ayudar a responder la pregunta.

Paso 3: formular hipótesis

Para comparar gasto promedio:

$$H_0 : \mu_A = \mu_B$$

$$H_1 : \mu_A \neq \mu_B$$

Deben explicar estas hipótesis usando lenguaje de negocio.

Paso 4: realizar la prueba

Para este ejercicio:

Welch t-test

Deben reportar:

- estadístico t ;
- valor p ;
- nivel α ;
- decisión estadística.

Paso 5: medir la diferencia

No basta con decir:

$$p = 0.03$$

También deben calcular:

$$\bar{x}_B - \bar{x}_A$$

y responder:

¿La diferencia es relevante?

Trampas del dataset

El dataset puede incluir:

- tamaños de muestra diferentes;
- valores extremos;
- distribuciones sesgadas;
- varianzas diferentes;
- pequeñas diferencias estadísticamente significativas.

Objetivo

No ejecutar automáticamente una prueba. Primero entender los datos.

Cada equipo deberá presentar:

- 1 pregunta;
- 2 hipótesis;
- 3 resumen descriptivo;
- 4 visualización;
- 5 prueba estadística;
- 6 valor p ;
- 7 diferencia observada;
- 8 interpretación;
- 9 recomendación.

“ $p = 0.03$, entonces existe 97 % de probabilidad de que mi hipótesis sea cierta.”

Incorrecto

El valor p no es la probabilidad de que una hipótesis sea verdadera.

“ $p > 0.05$, entonces demostramos que los grupos son iguales.”

Incorrecto

No encontrar evidencia suficiente de diferencia no demuestra igualdad.

“ $p < 0.05$, entonces el resultado es importante.”

Incorrecto


Significancia estadística no implica necesariamente importancia práctica.

“Tengo muchos datos, entonces mi análisis debe ser correcto.”

Incorrecto

Un dataset enorme puede seguir teniendo sesgos o problemas de diseño.

Pipeline de análisis estadístico



Objetivo	Función
Media	<code>mean()</code>
Mediana	<code>median()</code>
Moda	<code>mode()</code>
Varianza	<code>var()</code>
Desviación	<code>std()</code>
Percentiles	<code>quantile()</code>
Muestreo	<code>sample()</code>
Agrupar	<code>groupby()</code>
Resumen múltiple	<code>agg()</code>

Objetivo	Herramienta
Error estándar	<code>stats.sem()</code>
Intervalo de confianza	<code>stats.t.interval()</code>
Comparación de medias	<code>ttest_ind()</code>
Z-score	<code>zscore()</code>

12 ideas que deben recordar

- 1 Una muestra es una ventana hacia una población.
- 2 Una muestra grande no elimina automáticamente el sesgo.
- 3 La media no siempre representa correctamente los datos.
- 4 La dispersión importa tanto como el centro.
- 5 Las distribuciones contienen información importante.
- 6 Los estadísticos cambian entre muestras.
- 7 El Teorema Central del Límite explica el comportamiento de medias muestrales.
- 8 El error estándar mide incertidumbre de una estimación.
- 9 Los intervalos de confianza comunican precisión.
- 10 El valor p no es la probabilidad de que H_0 sea verdadera.
- 11 Significancia estadística no implica importancia práctica.
- 12 Correlación no implica causalidad.

Volvamos al inicio

Al comenzar preguntamos:

A:

12.1 %

B:

13.0 %

¿B es mejor?

Ahora nuestra respuesta cambia

No podemos responder solamente comparando:

12.1 %

contra:

13.0 %

Necesitamos considerar:

- tamaño de muestra;
- variabilidad;
- incertidumbre;
- diseño del experimento;
- significancia estadística;
- tamaño del efecto;
- relevancia para el negocio.

¿Qué cambia cuando aparece el tiempo?

Hasta ahora hemos analizado observaciones sin centrarnos demasiado en el momento en que ocurrieron.

Pero consideremos:

Ventas de enero



Ventas de febrero



Ventas de marzo



Ventas de abril

Aquí:

el orden importa

Una nueva clase de datos

Supongamos que tenemos:

$$X_1, X_2, X_3, \dots, X_t$$

donde cada observación corresponde a un momento diferente.

Aparecen preguntas nuevas:

- ¿Los valores actuales dependen del pasado?
- ¿Existe una tendencia?
- ¿Hay patrones que se repiten?
- ¿Existen ciclos?
- ¿Existe estacionalidad?
- ¿Podemos utilizar el pasado para entender el futuro?

Clase 7

Series Temporales I

Tendencia, estacionalidad y estructura temporal

Analizaremos:

- índice temporal;
- resampling;
- tendencia;
- estacionalidad;
- ciclos;
- ruido;
- medias móviles;
- ventanas móviles;

Estadística para Data Science

Los datos no hablan por sí solos.

La estadística nos ayuda a distinguir

señal

de

ruido.

Diplomado de Python y Análisis de Datos

Universidad Marista