

EDA: Encontrar Patrones

Data Detective

Análisis de Datos

Universidad Marista

Convertir datos en evidencia

Hoy aprenderemos a:

- Conocer un dataset.
- Resumir información.
- Encontrar patrones.
- Detectar anomalías.
- Comparar grupos.
- Encontrar relaciones.
- Visualizar evidencia.
- Formular hipótesis.
- Defender conclusiones con datos.

Pregunta central

¿Qué historia están contando nuestros datos?

Ruta de la investigación

- 1 Introducción a EDA
- 2 Anatomía del dataset
- 3 Estadística descriptiva
- 4 Variables y distribuciones
- 5 Outliers y anomalías
- 6 Descanso
- 7 Relaciones
- 8 Visualización
- 9 Data Detective
- 10 Reto por equipos
- 11 Conclusiones

¿Qué es EDA?

EDA significa:

Exploratory Data Analysis

Es el proceso de:

- explorar,
- resumir,
- visualizar,
- comparar,
- cuestionar

un conjunto de datos antes de construir modelos.

Idea importante

EDA no busca confirmar rápidamente una idea. Busca descubrir qué está pasando realmente.

¿Por qué necesitamos EDA?

Imaginemos un dataset:

$$X = \{x_1, x_2, \dots, x_n\}$$

Antes de aplicar Machine Learning necesitamos saber:

- ¿Qué representa cada variable?
- ¿Hay valores faltantes?
- ¿Hay errores?
- ¿Hay valores extremos?
- ¿Cómo se distribuyen los datos?
- ¿Existen grupos?
- ¿Existen relaciones?

EDA no es solamente hacer gráficas

Un EDA completo combina:

Datos + Estadística + Visualización + Pensamiento crítico

- Código para explorar.
- Estadística para resumir.
- Gráficas para observar.
- Contexto para interpretar.

Anatomía de un dataset

Un dataset puede representarse como una matriz:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

Donde:

- n = número de observaciones.
- p = número de variables.

Filas vs columnas

Fila

Representa normalmente una observación.

Ejemplo:

Edad	Carrera	Semestre	Promedio
20	MAC	6	8.4
21	MAC	7	9.1
19	Actuaría	4	7.8

Cada fila representa un estudiante.

Tipos de variables

Numéricas

- Edad
- Salario
- Promedio
- Temperatura

Categóricas

- Carrera
- Ciudad
- Sexo
- Tipo de cliente

Fecha / tiempo

- Fecha de compra
- Hora
- Año

Primer contacto con Python

```
1 import pandas as pd
2 df = pd.read_csv("dataset.csv")
3 print(df.head())
```

Preguntas:

- ¿Qué observamos?
- ¿Qué columnas existen?
- ¿Qué representa cada fila?

Tamaño del dataset

```
1 df.shape
```

Ejemplo:

```
1 (1000, 8)
```

Significa:

1000 observaciones

y

8 variables

Pregunta de detective

¿1000 filas significa que tenemos 1000 personas?

Conocer las columnas

```
1 df.columns
```

También:

```
1 df.info()
```

Nos permite conocer:

- nombres,
- tipos de datos,
- valores no nulos,
- memoria utilizada.

Valores faltantes

```
1 df.isnull().sum()
```

Ejemplo:

Variable	Faltantes
Edad	0
Salario	12
Ciudad	4
Promedio	0

Pregunta

¿Por qué podrían faltar esos datos?

La estadística descriptiva busca resumir los datos. Tres preguntas:

- 1 ¿Dónde están los datos?
- 2 ¿Qué tan dispersos están?
- 3 ¿Cómo se distribuyen?

Media

La media:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Ejemplo:

$$\begin{array}{c} 5, 7, 8, 10 \\ \bar{x} = \frac{5 + 7 + 8 + 10}{4} = 7,5 \end{array}$$

Cuidado

La media puede verse afectada por valores extremos.

Mediana

La mediana es el valor central después de ordenar los datos. Ejemplo:

2, 4, 5, 7, 100

La mediana es:

5

La media es:

23,6

Insight

La mediana puede representar mejor el centro cuando existen outliers.

La moda es el valor más frecuente. Ejemplo:

1, 2, 2, 2, 3, 4, 5

Entonces:

Moda = 2

Es especialmente útil para variables categóricas.

No basta con conocer el promedio. Necesitamos saber qué tan separados están los datos.
Medidas:

- Rango.
- Varianza.
- Desviación estándar.
- Rango intercuartílico.

Desviación estándar

La desviación estándar mide qué tan alejados están los datos de la media.

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Una desviación estándar grande implica mayor dispersión.

Pandas: resumen estadístico

```
1 df.describe()
```

Obtendremos:

- count
- mean
- std
- min
- 25 %
- 50 %
- 75 %
- max

¿Cómo se distribuyen los datos?

Una distribución responde:


¿Cómo se reparten los valores?

Podemos encontrar:

- Distribuciones simétricas.
- Distribuciones sesgadas.
- Concentraciones.
- Múltiples grupos.
- Colas largas.

Histograma

Un histograma divide los valores en intervalos llamados “bins”. Ejemplo conceptual:



Crear un histograma

```
1 import matplotlib.pyplot as plt
2 df["edad"].hist(bins=10)
3 plt.xlabel("Edad")
4 plt.ylabel("Frecuencia")
5 plt.title("Distribucion de edades")
6 plt.show()
```

Preguntas frente a un histograma

Nunca debemos solamente mirar la gráfica. Preguntemos:

- 1 ¿Dónde se concentran los datos?
- 2 ¿Hay valores extremos?
- 3 ¿Es simétrica?
- 4 ¿Tiene una cola?
- 5 ¿Hay más de un pico?

Una distribución puede estar sesgada. **Sesgo positivo:**

$$\text{Media} > \text{Mediana}$$

Sesgo negativo:

$$\text{Media} < \text{Mediana}$$

Esto nos ayuda a interpretar correctamente la media.

El boxplot resume:

- mínimo,
- primer cuartil,
- mediana,
- tercer cuartil,
- máximo,
- posibles outliers.

El rango intercuartílico es:

$$IQR = Q_3 - Q_1$$

¿Qué es un outlier?

Un outlier es una observación que se encuentra muy alejada del comportamiento habitual.

Ejemplo:

20, 21, 22, 23, 24, 120

El valor:

120

llama inmediatamente nuestra atención.

Definimos:

$$IQR = Q_3 - Q_1$$

Límite inferior:

$$Q_1 - 1,5(IQR)$$

Límite superior:

$$Q_3 + 1,5(IQR)$$

Los valores fuera de estos límites pueden considerarse outliers.

Detectar outliers con Python

```
1 Q1 = df["salario"].quantile(0.25)
2 Q3 = df["salario"].quantile(0.75)
3 IQR = Q3 - Q1
4 limite_inf = Q1 - 1.5 * IQR
5 limite_sup = Q3 + 1.5 * IQR
6 outliers = df[
7     (df["salario"] < limite_inf) |
8     (df["salario"] > limite_sup)
9 ]
10 print(outliers)
```

Un outlier no significa error

Un valor extremo puede ser:

- Error de captura.
- Error de medición.
- Fraude.
- Evento excepcional.
- Cliente especial.
- Fenómeno real.

Regla

No eliminamos un dato solamente porque sea extremo.

10 minutos Regresamos para investigar relaciones.

Relaciones entre variables

Ahora pasamos de:

X

a:

$X \longrightarrow Y$

Preguntamos:

¿Existe una relación entre dos variables?

Ejemplos:

- Horas de estudio $\rightarrow$ promedio.
- Publicidad $\rightarrow$ ventas.
- Edad $\rightarrow$ salario.
- Temperatura $\rightarrow$ consumo eléctrico.

La covarianza mide cómo cambian dos variables conjuntamente.

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

Interpretación:

- Positiva: tienden a crecer juntas.
- Negativa: una crece mientras otra disminuye.
- Cercana a cero: poca relación lineal.

El coeficiente de Pearson:

$$r = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Su rango es:

$$-1 \leq r \leq 1$$

- $r \approx 1$: relación positiva fuerte.
- $r \approx -1$: relación negativa fuerte.
- $r \approx 0$: poca relación lineal.

Correlación no implica causalidad

Si encontramos:

$$X \leftrightarrow Y$$

no significa automáticamente:

$$X \rightarrow Y$$

Puede existir:

- Una tercera variable.
- Una relación accidental.
- Sesgo de selección.
- Datos insuficientes.

Data Detective

Una correlación es una pista, no una sentencia.

Matriz de correlación

```
1 corr = df.corr(numeric_only=True)
2 print(corr)
```

Podemos buscar:

$$|r| \approx 1$$

para encontrar relaciones lineales fuertes.

Visualizar es construir evidencia

Una gráfica debe responder una pregunta. No:

“Hagamos una gráfica.”

Sino:

“Quiero comprobar qué ocurre con X cuando Y cambia.”

¿Qué gráfica usar?

Pregunta	Gráfica
¿Cómo se distribuye?	Histograma
¿Hay outliers?	Boxplot
¿Dos variables se relacionan?	Scatterplot
¿Cómo cambia en el tiempo?	Línea
¿Comparar categorías?	Barras
¿Muchas correlaciones?	Heatmap

Scatterplot

```
1 plt.scatter(  
2     df["horas_estudio"],  
3     df["promedio"]  
4 )  
5 plt.xlabel("Horas de estudio")  
6 plt.ylabel("Promedio")  
7 plt.show()
```

Pregunta:

¿Los estudiantes que estudian más obtienen mejores resultados?

Una buena visualización

Debe tener:

- Título.
- Ejes.
- Unidades.
- Escala adecuada.
- Leyenda cuando sea necesaria.
- Contexto.

Principio

La gráfica debe hacer evidente el patrón, no esconderlo.

Caso: El misterio del rendimiento

Tenemos información de estudiantes:

- Edad.
- Horas de estudio.
- Asistencia.
- Promedio.
- Carrera.
- Horas de sueño.

Misión

Descubrir qué factores parecen estar relacionados con el rendimiento académico.

Pista 1: Conocer la escena

Primero:

```
1 df.head()  
2 df.shape  
3 df.info()  
4 df.describe()
```

Preguntas:

- 1 ¿Cuántas observaciones existen?
- 2 ¿Qué variables tenemos?
- 3 ¿Hay datos faltantes?
- 4 ¿Hay valores imposibles?

Analizar:

- Edad.
- Horas de estudio.
- Promedio.
- Horas de sueño.

Utilizar:

- Histogramas.
- Boxplots.
- Estadística descriptiva.

Investigar:

HorasEstudio $\leftrightarrow$ *Promedio*

Asistencia $\leftrightarrow$ *Promedio*

Sueo $\leftrightarrow$ *Promedio*

Utilizar:

- Scatterplots.
- Correlaciones.

Pista 4: El sospechoso

Encontrar:

- El estudiante con menor promedio.
- El estudiante con mayor promedio.
- El estudiante con más horas de estudio.
- Valores extremos.

Después preguntar:

¿Son errores o casos reales?

Pista 5: La hipótesis

Cada equipo debe formular una hipótesis. Ejemplo:

“Los estudiantes que estudian más horas tienden a obtener mejores promedios.”

Después:

Hipótesis → Evidencia → Conclusión

DATA DETECTIVE

Cada equipo recibirá un dataset. Su misión:

- 1 Explorar.
- 2 Encontrar un patrón.
- 3 Encontrar una anomalía.
- 4 Encontrar una relación.
- 5 Crear evidencia visual.
- 6 Presentar una conclusión.

Reglas del reto

Cada equipo debe entregar:

- 1 Una pregunta.
- 2 Una hipótesis.
- 3 Una estadística.
- 4 Una gráfica.
- 5 Un hallazgo.
- 6 Una anomalía.
- 7 Una conclusión.

Importante

No gana quien haga más gráficas. Gana quien encuentre una historia interesante y pueda demostrarla.

Plantilla de investigación

Pregunta

¿Qué queremos descubrir?

Hipótesis

¿Qué creemos que ocurre?

Evidencia

¿Qué muestran los datos?

Conclusión

¿Qué podemos afirmar?

Limitación

¿Qué todavía NO podemos afirmar?

¿Qué aprendimos?

EDA nos permite pasar de:

Datos

a:

Datos → Patrones → Evidencia → Hipótesis

El proceso completo

- 1 Cargar los datos.
- 2 Conocer las variables.
- 3 Revisar calidad.
- 4 Describir estadísticamente.
- 5 Analizar distribuciones.
- 6 Detectar outliers.
- 7 Analizar relaciones.
- 8 Visualizar.
- 9 Formular hipótesis.
- 10 Comunicar hallazgos.

Checklist del Data Scientist

Antes de modelar:

- ☐ ¿Conozco mi dataset?
- ☐ ¿Sé qué representa cada variable?
- ☐ ¿Revisé valores faltantes?
- ☐ ¿Revisé duplicados?
- ☐ ¿Encontré valores extraños?
- ☐ ¿Conozco las distribuciones?
- ☐ ¿Busqué relaciones?
- ☐ ¿Visualicé los patrones?
- ☐ ¿Tengo hipótesis?
- ☐ ¿Puedo defender mis conclusiones?

No analices datos
para hacer gráficas. Analiza datos para
hacer preguntas mejores.

EDA → Machine Learning

Una vez que

conocemos nuestros datos...

¿Podemos hacer predicciones?

Preguntas ¿Quién encontró el patrón más interesante?